



RELATÓRIO PROVA – EDITAL 015/2025

João Pedro Banhato Pereira
joao.banhato@estudante.ufjf.br

DESENVOLVIMENTO DE TECNOLOGIA
ESTAGIÁRIO EM PESQUISA DE AVALIAÇÃO

Juiz de Fora, MG

2025

Sumário

1	Introdução	4
2	Ferramentas e Bibliotecas	4
3	Exploração dos Dados	5
3.1	title	6
3.2	tag	6
3.3	views	6
3.4	year	7
3.5	language	7
3.6	id	7
4	Análises Gráficas	8
5	Tratamento da Base	10
5.1	Remoção de Registros e Atributos Irrelevantes	10
5.2	Tratamento de Outliers em year	11
5.3	Normalização de Variáveis Numéricas	11
5.4	Limpeza Textual das Letras (lyrics)	11
5.5	Padronização de Nomes de Artistas (artist)	12
5.6	Tratamento de Colaborações (features)	12
5.7	Amostragem Balanceada por Gênero	12
6	Rede de Colaboração de Artistas	13
6.1	Nova Filtragem dos Dados	13
6.2	Construção do Grafo	14
6.3	Detecção de Comunidades	14
6.4	Métricas	15
6.4.1	Plotagem	16
7	Geração de Letras de Música	19
7.1	Amostragem e Filtragem Inicial	20
7.2	Resultados	21

8	Predição de Gênero Musical	22
8.1	Resultados para Regressão Logística	23
8.2	Resultados para Random Forest	24
9	Análise de Polaridade	25
10	Conclusão	28

1 Introdução

O presente trabalho envolve a manipulação, análise assim como o entendimento de uma base de dados que envolve informações acerca de músicas, como sua letra, os artistas envolvidos, ano de produção, entre outras. Neste sentido, no âmbito da ciência de dados, sabe-se que as bases de dados muitas vezes contêm dados não processados, os quais evocam uma tarefa prévia de *data cleaning*, de modo a preparar as instâncias para futuras manipulações.

Neste relatório, é descrito o processo de análise, pré-processamento e cumprimento de uma das tarefas (**rede de colaboração com grafo**), com o banco de dados mencionado anteriormente, além de resultados preliminares acerca das outras tarefas. Trata-se de um conjunto de dados de tamanho desafiador, exigindo uma abordagem minuciosa para seu tratamento e exploração.

As etapas realizadas procuram emular um fluxo de trabalho comum na prática de ciência de dados, passando desde a compreensão dos dados até a obtenção de novas informações ou a construção de modelos preditivos, a partir deles. Durante o desenvolvimento, ferramentas e bibliotecas da linguagem *python* foram utilizadas para análise, visualização, modelagem e avaliação dos dados. O relatório detalha cada uma das etapas seguidas no código fonte, mencionando as estratégias adotadas, os experimentos e as conclusões obtidas.

2 Ferramentas e Bibliotecas

Durante o desenvolvimento do projeto, foram utilizadas algumas bibliotecas do *python*. A seguir as principais são citadas, além de seus principais usos:

- **pandas**: manipular, filtrar e amostrar os dados (CSV) como *dataframes*;
- **numpy**: estatísticas, operações vetoriais;
- **matplotlib**: gerar figuras como histogramas e boxplots;
- **seaborn**: gerar figuras como countplots;
- **re**: manipular expressões regulares para limpeza de texto;

- `networkx`: criação de grafos, envolve nós e arestas ponderadas, além de métricas;
- `community_louvain`: algoritmo de Louvain para detecção de comunidades nos grafos;
- `scikit-learn`
 - `train_test_split`: separar dados em treino, validação e teste.
 - `TfidfVectorizer`: converte texto em vetores numéricos TF-IDF para modelo de classificação.
 - `MinMaxScaler`: normalização.
 - `LogisticRegression` `RandomForestClassifier`: modelos de classificação para prever gênero musical.
- `TextBlob`: cálculo de polaridade e sentimento das letras.
- `transformers` (Hugging Face) `GPT2Tokenizer`, `GPT2LMHeadModel`: fine-tuning de modelo GPT-2 para geração de texto.

3 Exploração dos Dados

Após importar o arquivo de dados no ambiente do *google colab*, percebe-se que o dataset contém mais de 260 milhões de registros, após contar suas linhas, o que impede a leitura completa de suas informações em ambientes com recursos limitados (que é o caso do *colab*). Neste sentido, para investigação inicial, foram importadas as primeiras 100 linhas e analisadas mais a fundo, obtendo:

- **Colunas iniciais:** 11.
- **Atributos presentes:**
 - `title` Título da obra.
 - `tag` Gênero musical.
 - `artist` Artista principal.
 - `year` Ano de produção.

`views` Número de visualizações.

`features` Colaboradores.

`lyrics` Letra.

`id` Identificador.

`language_cld3`, `language_ft`, `language` Saídas de detectores de idioma.

Além disso, após uma descrição do *dataframe* utilizado, foi possível perceber: há títulos não únicos (o que pode indicar duplicatas); a maior parte das instâncias não possui colaborações; a letra deverá ser tratada quanto a caracteres especiais e outros detalhes; visualizações e ano, como são numéricos, podem ser posteriormente normalizados.

Agora vale mencionar as estratégias utilizadas para estudar e tratar cada uma dessas variáveis:

3.1 title

Foi percebido que algumas amostras possuem títulos semelhantes, portanto foi pensado em uma maneira de verificar se são a mesma música ou somente possuem o mesmo título. Dessa forma, verificam-se o título, o artista e o ano de produção, simultaneamente, de modo a verificar se há duplicatas e as mesmas serem removidas.

3.2 tag

Quanto ao gênero, percebe-se que há 5 gêneros principais (pop, r&b, rock, country e rap), além de um intruso, que é *misc*, um gênero de miscelânea, que indica amostras como letras de livros, registros históricos, bíblicos, etc. E como as tarefas envolvem músicas, as amostras desse gênero foram removidas do banco de dados.

3.3 views

As amostras com número de visualizações zero foram removidas porque não possuem importância quando comparadas com o restante do banco. Além disso, foi notado que grande parte das amostras possuía uma quantidade de visualizações muito baixa (por volta de 100 a 1000), apesar de haver músicas famosas que, em pequena quantidade, se apresentavam como *outliers*. Portanto, foi pensado que, nas tarefas futuras, pode ser

pensado em definir um limiar de visualizações para obter amostras com colaborações significativas, e assim obter um grafo representativo de fato.

3.4 year

Como se sabe, as amostras, muitas vezes, podem conter dados errôneos, seja por erros de digitação, ou qualquer outro motivo. Portanto, ao verificar amostras com ano datado antes de 1900, percebeu-se, além de obras clássicas já esperadas, algumas músicas que claramente não pertenciam a esta época, como o caso de "The Severed Garden", de "The Doors", no banco com ano de 1878, quando na verdade deveria ser de 1978. Dessa forma, nessas amostras abaixo desse limiar definido como 1900, foram obtidas suas médias e desvio padrão, para comparar com o comum dentre esses artistas e, assim, remover as instâncias com datas incorretas. Foi pensado em remover em vez de usar a média, por exemplo, para não criar uma informação falsa, que posteriormente poderia ser usada.

3.5 language

Dessas informações, foi inicialmente proposto que as colunas de *language* informam os resultados de modelos como *CLD3* (*Compact Language Detector 3*) e *FastText* para o idioma da letra, e a coluna final *language* representaria o produto lógico entre elas, portanto, caso um dos modelos não tenha reconhecido o idioma (resultado *NaN*), o idioma resultante também seria *NaN*.

Dessa maneira, foi pensado um método que avaliava exatamente essas características nessas três colunas, de modo a deixar somente uma coluna de idioma final e reduzir a dimensionalidade da base de dados. Caso o idioma seja nulo na coluna *language*, mas haja algum idioma em uma das outras colunas, preenche o dado com esta informação. Porém, caso as colunas de inferência dos idiomas sejam conflitantes, essa amostra é removida. Assim, foi possível remover duas das colunas iniciais e ainda assim manter a informação necessária.

3.6 id

A variável identificadora, neste trabalho, não possui utilidade, portanto foi removida.

4 Análises Gráficas

De modo a iniciar algumas análises nos dados, foram removidas todas as duplicatas (levando em consideração todas as linhas) presentes no banco. Além disso, foram removidas as instâncias com valores vazios de cada coluna (exceto colaborações, já que uma música pode existir sem possuir colaborações). Para os gráficos a seguir, considera-se uma amostra com um milhão de instâncias.

Após essas ações mencionadas anteriormente, foram realizadas algumas análises gráficas, de modo a esclarecer mais pontos:




Figura 1: Distribuição de Músicas por Tag.

Observa-se que um *sampling* comum das amostras pode pegar amostras desbalanceadas por gênero, o que pode sugerir que novas estratégias sejam pensadas posteriormente.




Figura 2: Histograma de **views** em escala logarítmica.




Figura 3: Boxplot de **views** por gênero (escala log).

Percebe-se que o histograma de visualizações possui uma cauda longa a direita, indicando poucas amostras acima de um milhão de visualizações e suas amostras assemelhando-se a uma distribuição normal deslocada, então sugere um futuro tratamento dos valores *outliers*. Além disso, no *boxplot* separado por gêneros, é possível visualizar a presença massiva de músicas famosas como *outliers*.




Figura 4: Histograma de Número de Amostras por Ano de Lançamento.

Tal gráfico evidencia uma maior concentração de obras a partir dos anos 2000.

5 Tratamento da Base

Com base nas observações anteriores sobre limpeza de dados e em novas estratégias que serão elucidadas a seguir, foi estruturado um pipeline de limpeza e normalização das amostras, cujos principais passos foram descritos.

5.1 Remoção de Registros e Atributos Irrelevantes

1. **Duplicatas:** eliminação de linhas duplicadas, em 2 fases: considerando todas as colunas e considerando `title`, `artist` e `year` (de modo a remover músicas iguais nesses três atributos).
2. **Colunas removidas:** descarte de `id`, `language_cld3` e `language_ft`.
3. **Registros incompletos:** remoção de amostras com valores ausentes em qualquer um dos campos considerados essenciais: `title`, `tag`, `artist`, `year`, `views`, `lyrics`.
4. **Gênero misc:** exclusão de dados não estritamente musicais.
5. **views = 0:** eliminações de amostras sem visualizações.

5.2 Tratamento de Outliers em year

Amostras com `year < 1900` foram identificadas e, para cada artista, calculou-se média e desvio-padrão dos anos "válidos" (≥ 1900), e se comparou a média com o ano, a princípio, irregular. Foram removidas as instâncias em que a distância em relação à média superasse três vezes o desvio padrão.

5.3 Normalização de Variáveis Numéricas

As variáveis numéricas deviam ser normalizadas, são elas: `views` e `year`. Mas antes, de modo a comportar os *outliers* de visualizações, teve de ser feito um tratamento de usar o log de seu valor.

1. Aplicação de $\log(1 + \text{views})$ para "atenuar" os *outliers*.
2. Escalonamento de `views` e `year` para o intervalo $[0, 1]$ usando `MinMaxScaler`.




Figura 5: Boxplot das Visualizações Normalizadas por Gênero.

5.4 Limpeza Textual das Letras (lyrics)

Isso foi feito de modo a padronizar as letras para futura manipulação correta dos dados.

- Remoção de padrões de *timestamp*, padronização de espaços e quebras de linhas, marcadores, repetições excessivas, símbolos não alfanuméricos, dentre outros.

- Exclusão de letras com menos de 10 palavras ou mais de 10 000 caracteres, assim como entradas duplicadas ou vazias.

5.5 Padronização de Nomes de Artistas (artist)

Conversão para Title Case, remoção de espaços extras e caracteres especiais irrelevantes.

5.6 Tratamento de Colaborações (features)

1. Padronização da coluna para listas de nomes, contendo vírgulas.
2. Tratamento em cada nome (remover parênteses, barras invertidas, caracteres não-ASCII).
3. Filtrar colaboradores que correspondem ao próprio artista (auto collab) ou a termos como “chorus” ou “verse”.
4. Remoção das amostras em que o único colaborador seja o próprio artista.

5.7 Amostragem Balanceada por Gênero

Além disso foi definida uma estratégia para amostragem balanceada por *tag*, de modo que cada uma das cinco **tags** principais: **pop**, **rap**, **rock**, **country** e **rb** tenha representatividade semelhante, em caso de quantidade suficiente de dados para cada uma.

Por fim, finaliza-se com a base limpa, normalizada, balanceada e pronta para ser manipulada nas próximas tarefas, e garantindo que as análises não sejam enviesadas.




Figura 6: Distribuição do Número de Amostras por Gênero.

A tarefa escolhida para ser realizada foi a de construir a Rede de Colaboração de Artistas, entretando, posteriormente, também foram executadas tentativas de solucionar os outros problemas, que também estão explicitadas neste relatório.

6 Rede de Colaboração de Artistas

Após tratamento dos dados de maneira satisfatória, a tarefa atacada foi a de construir um grafo com uma rede de colaboração de artistas.

Dessa forma, para obter as colaborações musicais de cada artista, deve ser obtido um grafo, não direcionado, no qual cada um dos nós representa um artista e cada aresta vai conectá-lo a outro artista que colaborou em ao menos uma instância, tendo cada aresta o peso do número de colaborações entre aqueles artistas, ou seja, quanto mais colaborações tiveram juntos, de maior peso será essa conexão.

6.1 Nova Filtragem dos Dados

1. **Amostra Balanceada:** utilizou-se a amostra previamente balanceada por gênero, com 150 mil entradas, para cada gênero.

2. **Filtragem por Popularidade:** as músicas com **views** abaixo de percentil 10% foram removidas, de modo que o grafo possa evidenciar colaborações com uma visibilidade mínima.
3. **Colaborações Explícitas:** amostras sem colaborações foram removidas para esta tarefa, já que não evidenciam conexões.
4. **Mínimo de Colaborações:** foi definido um mínimo de 10 músicas colaborativas de modo a remover as músicas esparsas.
5. **Top 20% por Views:** por fim, foi pensado que seria interessante manter somente as músicas dentro do top 20% de visualizações, de forma a garantir que houvesse representações conhecidas e impactantes, para poder comprovar a capacidade do grafo com artistas mais conhecidos.

6.2 Construção do Grafo

1. Para cada linha do *dataframe* filtrado, foi capturada uma lista com os colaboradores da coluna **features**, por meio de expressões regulares, com os artistas entre vírgulas.
2. Para cada par (artista e colaborador), uma aresta é adicionada no grafo, sendo o peso dessa aresta o número de colaborações.
3. Os nós isolados, ou seja, de artistas sem colaborações, foram removidos.

6.3 Detecção de Comunidades

Foi utilizado o algoritmo de *Louvain* para detectar as comunidades presentes no grafo, o qual maximiza a modularidade da partição. As comunidades foram buscadas como dicionário de artista para um identificador de comunidade. Então, os nós foram agrupados por suas comunidades e foi calculada a modularidade global. Foram evidenciadas as comunidades (por identificador e número de membros) e listados os artistas de cada comunidade.

6.4 Métricas

Algumas métricas foram consideradas para obter informações acerca de cada grafo representado, são elas:

- **Modularidade Louvian:** indica a densidade de arestas dentro da própria comunidade do que fora dela.
- **Degree Centrality:** quantos colaboradores o artista (nó) possui.
- **Betweenness Centrality:** a frequência em que um artista aparece nos caminhos mais curtos entre outros pares.
- **Closeness Centrality:** distância média de um artista a todos os restantes.
- **Comprimento Médio de Caminho:** distância média dos caminhos mais curtos.
- **Número e Tamanho das Componentes Conectadas.**

6.4.1 Plotagem




Figura 7: Grafo com os 100 artistas com maiores graus (com mais conexões), coloridos por comunidade, com tamanho de nó proporcional ao grau e grossura da aresta de acordo com o peso.

A figura anterior mostra as 8 comunidades obtidas nas condições comentadas. Evidenciando que artistas de gêneros semelhantes tendem a estar na mesma comunidade, como os *rappers* em marrom. Além de ser possível visualizar que há artistas-ponte, os quais são nós maiores, devido ao seu alto grau, já que servem de conexão para diversos outros artistas, sejam eles da mesma comunidade ou não.

As métricas obtidas em cima desse grafo confirmam uma estrutura com comunidades bem conectadas, devido a uma modularidade Louvain de 0.5362 e somente duas componentes conectadas, com a maior delas contendo 94 artistas. Além disso, a média de caminhos mais curtos foi de 3.68, característica típica de redes do *small world*, em que se pode alcançar outros nós com pouquíssimos passos, conhecida no imaginário popular como a teoria dos sete graus de separação. Quanto às centralidades, artistas como Jay-Z, Chris Brown, Rihanna e Kanye West foram os mais influentes, seja quanto à centralidade de grau (artistas com mais colaborações), betweenness (pontes entre grupos distintos) ou closeness (acessibilidade dos nós ao resto da rede), sendo Jay-z o destaque dessas três métricas.

Além disso, de modo a obter mais informações, foram plotados grafos separados por gênero também.




Figura 8: Grafo do gênero pop com os 100 artistas com maiores graus (com mais conexões), coloridos por comunidade, com tamanho de nó proporcional ao grau e grossura da aresta de acordo com o peso.

No grafo do gênero pop, imediatamente já é possível notar novamente as comunidades estruturadas, confirmado com modularidade Louvain de 0,6969, com os artistas colaborando mais dentro de suas comunidades do que fora. A rede de colaborações possui 6 componentes conectadas, ou seja, é bem mais fragmentada que no caso anterior, porém a maior componente segue contendo um número alto de artistas (83). A média do comprimento dos caminhos mais curtos nessa maior componente foi de 5,53, indicando que é necessária aproximadamente 2 conexões a mais que no caso anterior. Os artistas com

maior centralidade foram Rihanna, Kanye West e Justin Bieber, destaques nas métricas de centralidade de grau, intermediação e proximidade, ou seja, são nós fundamentais na rede para alcançar outros artistas.

Dessa maneira, podemos concluir que a representação em formato de grafo é capaz de trazer informações relevantes acerca das colunas de artista, colaborações e gênero, uma vez que realça exatamente como cada artista se conecta com outros, o que, aliado às métricas, sugere tendências em relação ao comportamento dos artistas de determinado gênero entre si e com outros gêneros. Entretanto, devido à extensão da base de dados original, é importante salientar que esta maneira de representação possui limitações, uma vez que a análise é feita em apenas uma amostra da base de dados completa, além de serem filtradas as amostras de maior relevância em visualizações, portanto, considerando que é possível que determinados artistas famosos não foram incluídos nessa amostragem, pode haver melhoria nesse sistema de representação, em vez de amostrar por número de visualizações, somente, pode ser pensado em combinar também com uma série de contribuições relevantes, que possuam colaboração, de modo a construir uma amostra que seja ainda mais voltada para essa representação. Ressalta-se também que, ao filtrar as amostras com maior quantidade de visualizações, de modo a obter conexões mais representativas em termo de artistas mais estabelecidos, grande parte das amostras de gêneros como rock, rb e country foram desfavorecidas, contendo bem menos de 100 amostras, o que gerou grafos pouco conectados dessas amostras. Dessa maneira, pode ser pensado em estratégias de não filtrar pelas visualizações para esses casos ou de obter tais amostras separadamente com mais quantidade de dados.

Além disso, destaca-se que com maior poder computacional (seja com recursos ou horas de execução do código), pode ser possível obter uma fração mais representativa dos dados originais para poder se afirmar com maior certeza as tendências dentro de cada grafo.

7 Geração de Letras de Música

Após finalizada a tarefa anterior, foram realizadas **tentativas** de resolver os outros problemas. Portanto, considera-se que os problemas a seguir apresentam resultados preliminares, em grande parte. O próximo problema atacado foi o de geração de letras de

músicas.

Nesse item, foi construído um modelo generativo que, ao receber um prompt inicial que representa um trecho musical, é capaz de completar o restante dessa música.

7.1 Amostragem e Filtragem Inicial

Foi utilizada a base de dados filtrada depois do pré processamento como ponto de partida. A partir disso, as músicas com `views` abaixo de percentil 10% foram removidas, de modo a manter amostras com certa relevância. Enfim, de modo a construir um modelo eficaz, foram selecionadas apenas as amostras com idioma em inglês (`language == 'en'`), as quais eram as de maior quantidade.

Em seguida, de modo a treinar o modelos com as amostras de melhor qualidade, foram removidas as entradas com menos de 50 caracteres, para que letras insuficientes ou ruídos não atrapalhassem o processo de geração de letras. Associado a isso, foi feita uma verificação quanto ao tamanho das letras presentes nas amostras, o que garantiu que as amostras eram de tamanho suficiente para serem treinadas.




Figura 9: Comprimento das letras em escala log.

Após isso, de modo a estruturar o corpus, todas as letras foram concatenadas em um

arquivo de texto, em que cada linha representava uma letra de uma instância. Com ele, foi montado uma base de dados no formato Hugging Face, dividida em treino (80%), validação (10%) e teste (10%). Em seguida, na tokenização, foram usadas janelas de 128 tokens. Agora, com um modelo pré treinado do GPT2 (head model), foi possível iniciar o treinamento do modelo. O valor de batch de 16, de 3 a 5 épocas, com um learning rate de 5e-5, para evitar overfitting. Ao final do treinamento, é avaliada a perplexidade no conjunto de validação, para estimar o quão incerto o modelo está acerca da próxima palavra.

Para a geração, o modelo e o tokenizer pós *finetuning* foram obtidos, e foram definidas algumas variáveis: tamanho máximo de 100 tokens a mais que o prompt original, temperatura de 0.7 a 0.9 de modo a obter respostas, respectivamente, mais contidas ou mais criativos comparadas com os dados de treino, penalidade de repetição de 1.5 para evitar que o modelo travasse repetindo palavras, e foi proibida a repetição de sequências de 3 palavras repetidas, em suma. De modo a fazer um teste, foi utilizado o seguinte prompt: ***“I got a confession to make”***.

7.2 Resultados

Primeiramente, devido ao fato do processo de treinamento ser pesado computacionalmente (extenso em termos de tempo de execução e consumo de GPU), foi necessário utilizar uma quantidade mais reduzida de dados, com 5000 amostras, equalitariamente equilibradas entre cada um dos gêneros. Utilizando 3 épocas, o treinamento foi finalizado com uma loss de 3.51 e a loss na validação foi de 3.61, com perplexidade de 36.97. Tais resultados indicam que o modelo ainda está longe de convergir ou de representar corretamente novas amostras a partir dos dados fornecidos.

A saída completada por este modelo foi: ***“I got a confession to make I’m on the run, I ain’t ever gonna let you down Never fear, I’ll give you everything that ya need You and me together will never be the same ’Cause we can do it all We don t wanna fight And if we makin’ mistakes But hey yo baby just keep doing what yall done Yo Baby this is for my homie who love him too much He said he wish his daddy was there with us This would have been easy Been around since then Oh no No It”***.

Percebe-se que, apesar de fazer sentido léxico por grande parte da resposta, ainda é possível notar resquícios de letras do treinamento sendo simplesmente replicadas na

geração, além de algumas palavras soltas sem fazer muito sentido. Isso pode ser explicado por conta da pequena quantidade de dado fornecida ao modelo, além de poucas épocas de treinamento.

Entretanto, uma alternativa foi pensada para avaliar o modelo: limitar o gênero para somente um, como pop, e treinar o modelo com base nesses dados. Então, dos dados usados anteriormente, foi selecionada somente a seção com gênero pop para ser treinada, com 5 épocas. O modelo apresentou uma loss de treinamento de 2.85 e na validação de 3.21, com perplexidade de 24.77, valores ainda altos, porém a limitação de gênero foi eficaz na redução da loss no treinamento, o que pode ser explicado devido ao fato que amostras de gêneros semelhantes tendem a possuir letras que, de certa maneira, abordam temas parecidos ou possuem um conjunto de palavras também parecido.

A resposta do modelo anterior do gênero pop: *“I got a confession to make I’m confess, I’m not the only one You see my heart is bleaching red And you’re telling me that it’s all in good fun? Well, baby girl Let s get this thing straight ’Cause if your daddy was black He’d be chewing gum right now Don’t wanna talk about his shoes or what So why am i acting like This ain t no love letter If he wasn dancin’ I wouldn-ah do anything But just kiss and tell Yeah! Baby letz”*.

Ainda é possível perceber que as respostas não estão fazendo muito sentido e estão desconexas, entretanto, na parte “I’m confess”, percebe-se que o modelo fez sentido com relação a frase inicial anterior. No entanto, ainda assim, a validação indica que o modelo ainda não aprendeu conforme aprendeu no treinamento, portanto ainda há muito espaço para evolução, ao serem variados os parâmetros do treinamento, como épocas, learning rate e tamanho do batch.

- **Eval Loss:** informada depois da validação (2.85).
- **Perplexity:** calculada como $\exp(\text{eval_loss})$ (17.3).

8 Predição de Gênero Musical

Em seguida, a próxima tarefa atacada foi a de prever o gênero musical da instância, a partir de sua letra. Para isso, foi preciso obter um classificador que preveja a **tag** de uma música a partir de sua letra (**lyrics**).

Os dados filtrados passaram por uma nova filtragem semelhante ao da tarefa anterior, ou seja, foram mantidas amostras com visualizações acima do 10% percentil e somente amostras em inglês, além de serem removidas amostras com menos de 50 caracteres. O número de amostras balanceadas por gênero utilizado nesta tarefa foi de 10 mil amostras para cada gênero, de modo que o preditor fosse alimentado com quantidade suficiente e equalitária para cada uma das *tags*.

A partir disso, os dados foram divididos em conjuntos de treino (70%), validação (15%) e teste (15%) com `stratify` por gênero.

O modelo de classificação necessita de representações numéricas das letras, portanto foi utilizada vetorização TF-IDF (Term Frequency–Inverse Document Frequency), a qual calcula a relevância de palavras considerando a frequência local (para cada amostra) e global (corpus), o que reduz a importância de palavras muito comuns e que não agregam. O vocabulário consiste nas 30 mil palavras mais frequentes, considerando unigramas e bigramas e trigramas, de modo a entender sequências. Também foram removidos stopwords do idioma inglês.

Para o treinamento do classificador, foram usados dois modelos: regressão logística e random forest. Quanto à regressão logística, foi utilizado um número máximo de 1000 iterações, para tentar garantir a convergência. Quanto ao Random Forest, foram usadas 200 árvores de decisão e uma profundidade máxima de 30.

De modo a avaliar cada um dos modelos, foi gerado o classification report, que abrange as métricas de precisão, recall e F1-score para cada classe. Tais métricas permitem verificar os resultados do modelo em cada gênero separadamente e também de forma geral. Além disso, foi feita uma demonstração de predição para uma amostra aleatória do conjunto de teste. Dessa forma, exibem-se as probabilidades para cada classe além de o label original assim como o predito.

8.1 Resultados para Regressão Logística

Classification Report:

	precision	recall	f1-score	support
country	0.63	0.68	0.66	1500
pop	0.47	0.50	0.49	1500

rap	0.89	0.85	0.87	1500
rb	0.63	0.64	0.64	1500
rock	0.53	0.47	0.50	1500
accuracy			0.63	7500
macro avg	0.63	0.63	0.63	7500
weighted avg	0.63	0.63	0.63	7500

8.2 Resultados para Random Forest

Classification Report:

	precision	recall	f1-score	support
country	0.65	0.59	0.62	2000
pop	0.47	0.70	0.56	2000
rap	0.83	0.91	0.87	2000
rb	0.65	0.61	0.63	2000
rock	0.62	0.33	0.43	2000
accuracy			0.63	10000
macro avg	0.64	0.63	0.62	10000
weighted avg	0.64	0.63	0.62	10000

Ambos os métodos (apesar da diferença de 500 amostras para cada gênero entre os métodos) apresentaram precisão geral semelhante, por volta de 64%, o que indica que o modelo é capaz de prever o gênero. Entretanto, pode-se notar também o desequilíbrio de precisão entre os gêneros, ou seja, rap possui uma precisão muito maior (83%) que pop (47%), por exemplo, o que indica que deve ser feita uma análise mais profunda acerca desse problema. Uma das maneiras seria uma otimização dos hiperparâmetros dos métodos, de modo a obter o melhor resultado possível.

9 Análise de Polaridade

Por fim, para a análise de polaridade, é necessário avaliar o sentimento das letras de música. Além disso, é avaliada a evolução ao longo do tempo dessa polaridade para determinado artista e verificada se há relação entre polaridade e *views*. Neste sentido, foi utilizada a amostra balanceada de dados, considerando somente as amostras em inglês.

Foi utilizada a estratégia para análise de sentimento no texto TextBlob, que pontua as letras com polaridade entre -1 e 1, com valores negativos indicando sentimentos negativos, próximos a zero indicam neutralidade, e positivos refletem sentimentos positivos.

A classificação seguiu a lógica: negativa (polaridade menor ou igual a -0.05), neutra (entre -0.05 e 0.05), ou positiva (maior ou igual a 0.05). Dessa maneira podemos avaliar o sentimento da música.

Os resultados de polaridade foram compilados por artista e por ano, usando uma amostra de tamanho 5000, para o gênero rap, uma vez que esse gênero costuma apresentar uma variedade de temas em suas composições, portanto espera-se certa polaridade. Ou seja, para cada combinação de artista e ano, foi calculada a média da polaridade das músicas lançadas, assim como o desvio padrão, e também a média de visualizações dessas músicas. Assim, pode-se analisar a evolução do conteúdo emocional e da popularidade ao longo do tempo para cada artista.

Pode-se plotar gráfico da evolução da média de polaridade ao longo do tempo para determinado artista. Como exemplo, analisamos o caso do rapper Kanye West, conhecido por suas músicas terem refletido seu transtorno de bipolaridade, o que interferiu nas letras ao longo do tempo. Dessa forma, pode-se perceber mudanças de fase na carreira ou contexto (como problemas pessoais) sobre o estilo do artista nas letras.




Figura 10: Variação da Polaridade do Artista Kanye West com o passar dos anos na amostra.

Neste sentido, observa-se que, em 2010, por exemplo, a polaridade desceu, devido ao fato do lançamento do álbum "My Beautiful Dark Twisted Fantasy", no qual tópicos sensíveis foram mencionados por ele durante toda a extensão do disco.

Além disso, foram obtidas as músicas de maior e menor polaridade para Kanye West, sendo a mais positiva chamada Amazing que fala sobre exaltação pessoal, superação, autoconfiança e resiliência, enquanto a mais negativa fala sobre um relato de uma traição amorosa, confirmando que o modelo pôde analisar bem a polaridade das canções.

De modo a identificar quais artistas mudaram mais seu estilo emocional com o tempo, basta calcular a diferença entre o maior e o menor valor de polaridade média anual, para cada artista. Isso evidencia a amplitude de variação emocional do artista. Compila-se, por exemplo, os 10 artistas com maior variação entre sentimentos positivos e negativos dentro da amostra.

	artist	var_total
0	Spose	0.851122
1	Wyclef Jean	0.622917
2	The Lonely Island	0.591779

3	Missy Elliott	0.570321
4	Mac Dre	0.495746
5	Dj Khaled	0.486360
6	D12	0.458763
7	King T	0.446316
8	The Notorious BIG	0.428496
9	Beastie Boys	0.388665

Por fim, plota-se a relação entre o sentimento das letras e a popularidade das músicas, medida pelo número de visualizações. Nesse sentido, a princípio, não é possível observar uma relação firme entre sucesso e polaridade. Entretanto, percebe-se que grande parte das amostras possuem polaridade baixa.




Figura 11: Relação de views com polaridade.

Dessa forma, para posteriores estudos, seria possível analisar amostras com maior quantidade de gêneros distintos, além de uma quantidade maior de amostras, de modo a possibilitar tomar uma conclusão mais consistente acerca da relação de polaridade e sucesso.

10 Conclusão

O trabalho presente foi considerado de extrema valia por conta da variedade de análises e possibilidades de modelagem diferente do problema, além do aspecto desafiador, que muitas vezes funcionou como motivação e recompensa quando determinado resultado era atingido. Neste sentido, sinto que pude colocar meus conhecimentos acerca de ciência de dados à prova, por meio dessa prática, além de ter aprendido mais profundamente sobre diversos tópicos, devido à pesquisa e treino. Avalio que consegui apresentar um resultado interessante quanto a proposta dos grafos e resultados preliminares quanto aos outros problemas, o que não impede que haja evolução nesses conceitos no futuro.

Referências

Bernardino H. S. Notas de aula da disciplina Mineração de Dados - DCC127, Departamento de Ciência da Computação UFJF, 2025.